

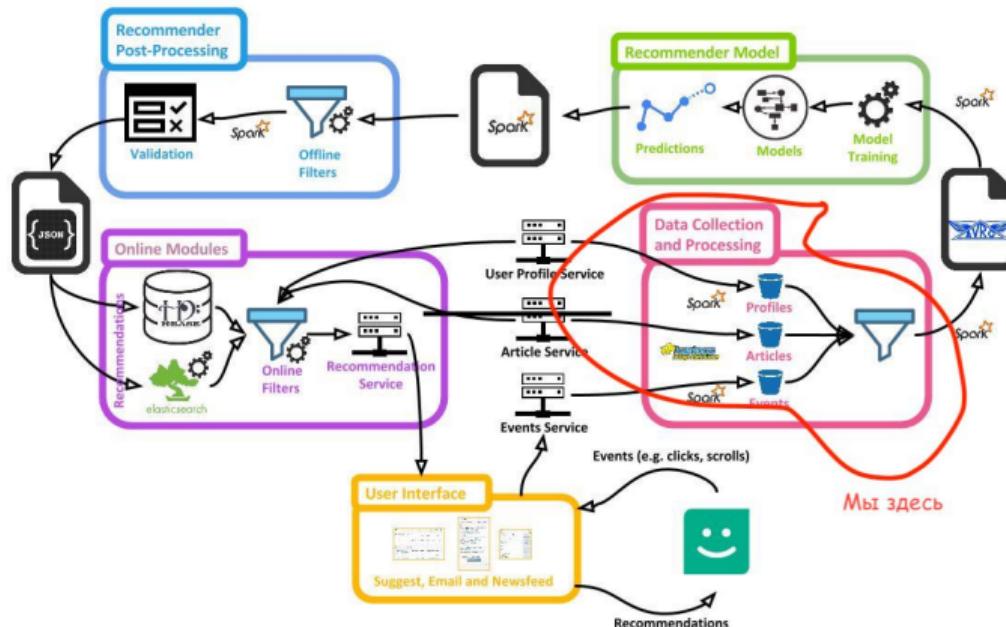
# Метрики и базовые подходы

Николай Анохин

2 июня 2022 г.



# Контекст



**Оценка успешности идей**  
●ooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
oooo

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

## Оценка успешности идей

Оценка успешности идей  
о●oooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
oooo

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

## Научный метод



Чем быстрее проходим все этапы, тем быстрее улучшаем сервис

## A/B эксперимент [RRSK10]

### Плюсы

- Надежная оценка эффекта на любую метрику

### Минусы

- Риск необратимо расстроить пользователей
- Риск финансовых потерь
- Дорого заводить
- Долго ждать результат
- Метрик не всегда достаточно

Оценка успешности идей  
ооо●оо

Оффлайн эксперимент  
оооо

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
оооо

Удачность  
оооооо

Бейзлайны  
oo

Итоги  
ooo

## Миссия социальной сети

Helping users feel closer to their friends and family.

Q: Какую метрику вы бы предложили измерять в A/B?

## Опрос пользователей

### Плюсы

- Полный контроль над экспериментом
- Оценка эффекта на любую метрику
- Собрать фидбэк напрямую

### Минусы

- Дорогой сбор данных
- Смещение аудитории
- Нечестный фидбэк

## Оффлайн эксперимент

### Плюсы

- Большая скорость проверки гипотез
- Нельзя сломать прод

### Минусы

- Не все метрики доступны офлайн
- Смещение выборки
- Результат не обязан обобщаться

Оценка успешности идей  
oooooooo

Оффлайн эксперимент  
●ooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
oooo

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

## Оффлайн эксперимент

## Бизнесовая метрика

напрямую интересует бизнес

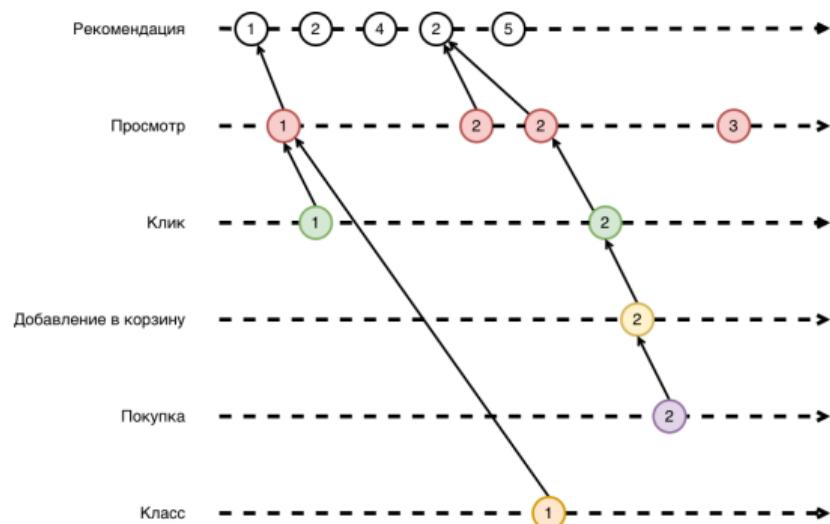
- сложно оптимизировать
- сложно понять, как компоненты системы влияют на метрику
- сложно мерить онлайн

## Техническая метрика

отражает один аспект системы

- можно оптимизировать
- можно померить онлайн
- не интересует бизнес :(

## Какой бывает фидбэк



### Техническая метрика

- Явный/explicit
- Неявный/implicit
- Отложенный/delayed

При оффлайн оценке нужно стремиться к тому, чтобы данные были максимально похожи на реальность

## Техники выбора данных для оффлайн оценки

- Семплировать случайные пары user-item
- Семплировать случайные item у каждого пользователя
- Семплировать тестовых пользователей
- Тестовые данные после обучающих по времени
- Написать симулятор системы

Оценка успешности идей  
оооооо

Оффлайн эксперимент  
оооо

**Релевантность**  
●oooooooooooo

Покрытие  
ooo

Разнообразие  
ооооо

Удачность  
оооооо

Бейзлайны  
oo

Итоги  
ooo

## Релевантность

Оценка успешности идей  
оооооо

Оффлайн эксперимент  
оооо

Релевантность  
о●oooooooooooo

Покрытие  
ooo

Разнообразие  
ооооо

Удачность  
оооооо

Бейзлайны  
oo

Итоги  
ooo

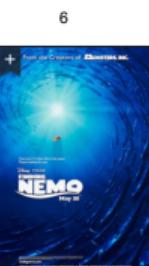
## Pinkamena Diane Pie



A comic relief character [...] appears to be the naive party animal of the group, she also displays admirable skill in science and engineering.

## Релевантность

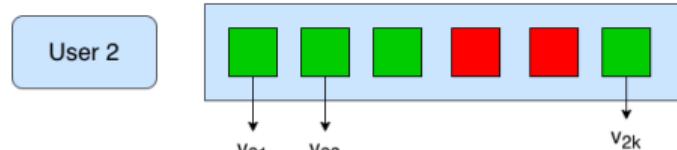
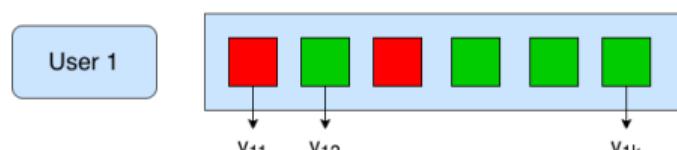
Насколько рекомендации соответствуют вкусам пользователя?



## Метрики точности

 Non-relevant item

 Relevant item



RMSE, MAE, accuracy, precision, recall, auc, ...

## Метрики ранжирования



Non-relevant item

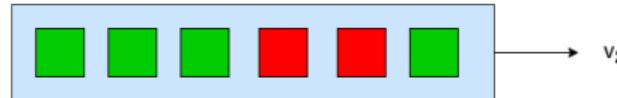


Relevant item

User 1



User 2



## Precision@k, Recall@k

- Non-relevant item
- Relevant item

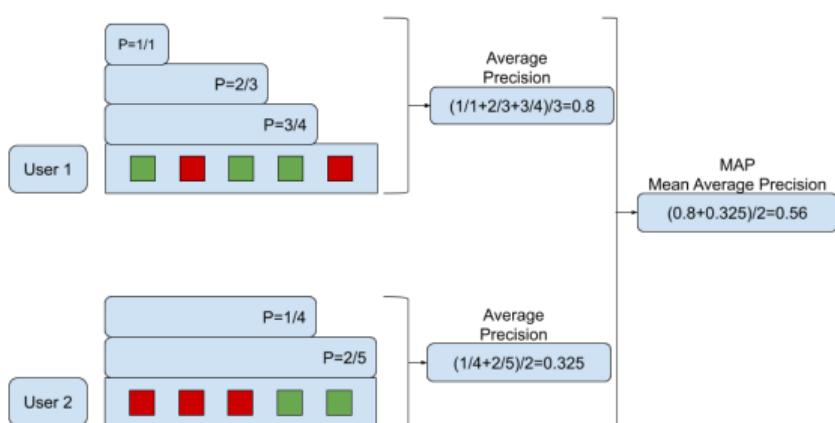


- Легко интерпретировать
- Легко реализовать

- Нечувствительны к порядку внутри  $k$
- Не дают общей картины для любого  $k$

## Mean Average Precision [Tai19]

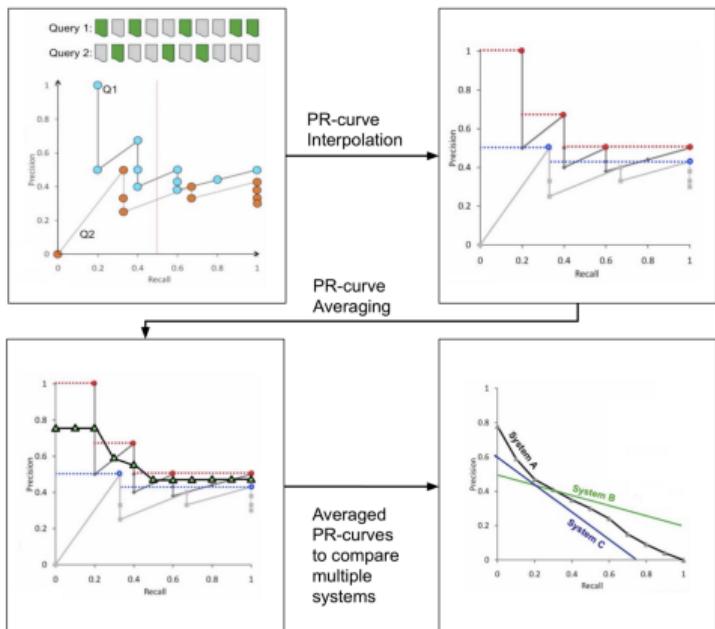
■ Relevant Item  
■ Non-Relevant Item



- Дают общую картину качества
- Больше внимания айтемам в голове списка

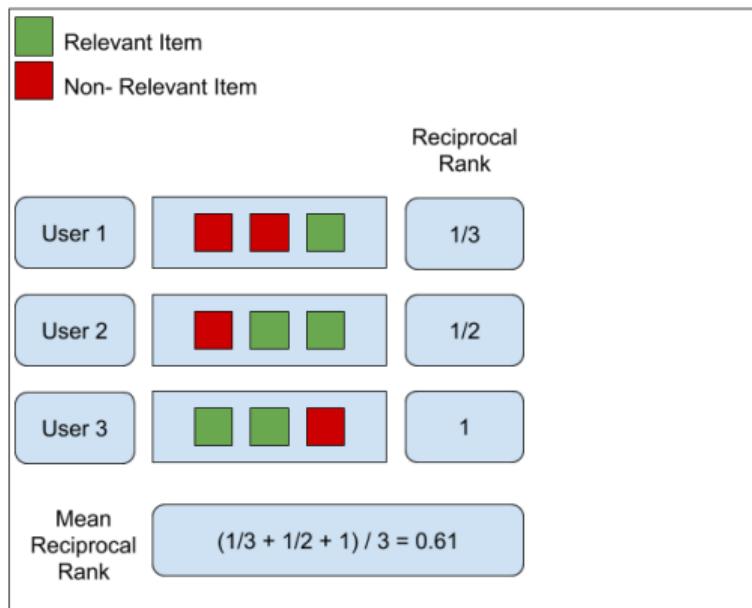
- Подходит только для бинарного фидбэка

## Area Under Precision-Recall curve



Визуальное представление  
MAP

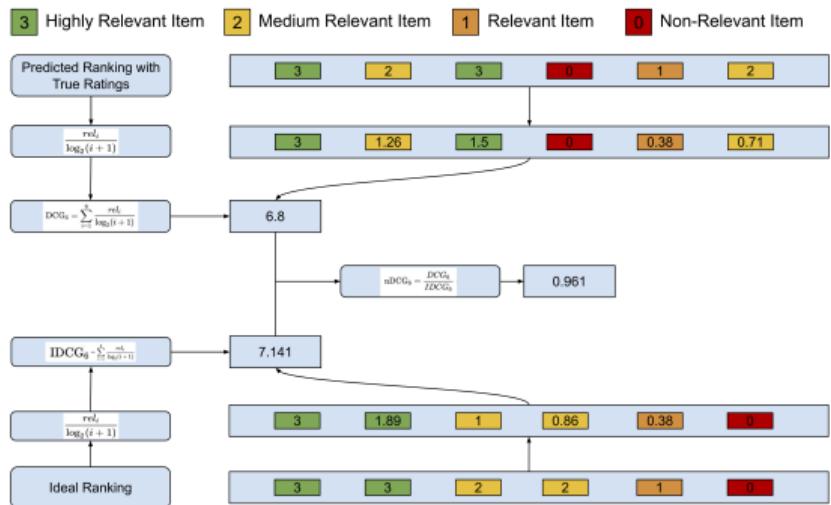
## MRR



- Легко интерпретировать
- Легко реализовать
- Удобна для задач, где имеет значение первый результат

- Учитывает только первый результат
- Быстро убывает

## [N]DCG



- Учитывает не только бинарный фидбэк
- Хорошо учитывает позицию

- Сложно интерпретировать

Оценка успешности идей  
оооооо

Оффлайн эксперимент  
оооо

Релевантность  
oooooooooooo●

Покрытие  
ooo

Разнообразие  
оооо

Удачность  
оооооо

Бейзлайны  
oo

Итоги  
ooo

## Гайд по выбору метрик Николая Анохина

1. Находим метрики релевантности, которые подходят к задаче
2. Выбираем в качестве основной самую интерпретируемую
3. Усложняем метрику, если оказалось, что она не отражает реальность

Оценка успешности идей  
oooooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
●○○

Разнообразие  
oooo

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

## Покрытие

## Item space coverage

Какую долю из всех возможных айтемов умеет рекомендовать сервис?

$$cov = \frac{|I_p|}{|I|}$$

$$gini = \frac{1}{|I|-1} \sum_{j=1}^{|I|} (2j - |I| - 1)p(I_j)$$

$p^1(I_j)$  – частота, с которой пользователи выбирают айтем  $I_j$

$p^2(I_j)$  – частота, с которой рекомендер показывает айтем  $I_j$

Айтемы отсортированы по возрастанию  $p(I_j)$

Оценка успешности идей  
оооооо

Оффлайн эксперимент  
оооо

Релевантность  
оооооооооооооо

Покрытие  
оо●

Разнообразие  
оооо

Удачность  
оооооо

Бейзлайны  
оо

Итоги  
ооо

## User space coverage

Доля пользователей, которые могут получить рекомендации

Оценка успешности идей  
oooooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

**Разнообразие**  
●ooo

Удачность  
oooooo

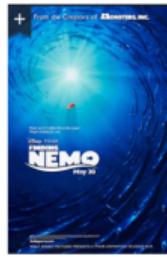
Бейзлайны  
oo

Итоги  
ooo

## Разнообразие

## Разнообразие [KP17]

[diversity] Насколько разнообразные айтемы в списке рекомендаций пользователя?



Оценка успешности идей  
oooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
ooo●o

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

$$div(u) = \frac{\sum_{i=1}^n \sum_{j=1}^n (1 - similarity(i,j))}{n/2(n-1)}$$

With 1% precision loss, percentage of rec. long-tail items increases from 16 to 32, with 5% loss perc. increases to 58.

Метрика сильно зависит от того, как определить сходство

Оценка успешности идей  
oooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
ooo●

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
ooo

## Maximal Marginal Relevance [CG98]

$$MMR = \max_j \left[ \lambda \text{similarity}(j, U) - (1 - \lambda) \max_{k < j} \text{similarity}(k, j) \right]$$

Оценка успешности идей  
oooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
oooo

Удачность  
●ooooo

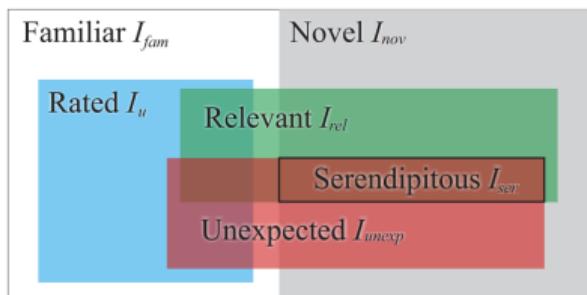
Бейзлайны  
oo

Итоги  
ooo

## Удачность

## Удачность

The term **serendipity** has been recognized as one of the most untranslatable words. The first known use of the term was found in a letter by Horace Walpole to Sir Horace Mann on January 28, 1754. The author described his discovery by referencing a Persian fairy tale, “The Three Princes of Serendip”. The story described a journey taken by three princes of the country Serendip to explore the world. In the letter, Horace Walpole indicated that the princes were “always making discoveries, by accidents and sagacity, of things which they were not in quest of”. [KWV16]



Оценка успешности идей  
ooooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

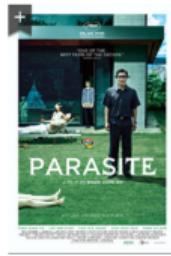
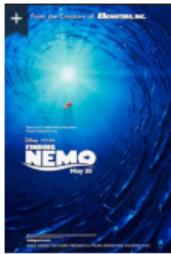
Покрытие  
ooo

Разнообразие  
oooo

Удачность  
oo●ooo

Бейзлайны  
oo

Итоги  
ooo



## Новизна

[novelty] Насколько айтем неизвестен пользователю?

Идея 1: Насколько айтемы близки к айтемам из истории пользователя?

$$nov^1(u, i) = \min_{j \in I_u} dist(j, i)$$

Идея 2: Насколько айтемы близки к популярным?

$$nov^2(u, i) = 1 - \frac{|U_i|}{|U|}$$

## Неожиданность

[unexpectedness] Насколько пользователь ожидает увидеть в рекомендациях айтем?

$$nPMI(i, j) = -\log \frac{p(i, j)}{p(i)p(j)} / \log p(i, j)$$

$$unexp(u, i) = \max_{j \in I_u} (-nPMI(i, j))$$

Оценка успешности идей  
ооооооОффлайн эксперимент  
ооооРелевантность  
ооооооооооооПокрытие  
оооРазнообразие  
ооооУдачность  
ооооо●Бейзлайны  
ооИтоги  
ооо

Цель	rel	cov	div	ser	poll
<b>Бизнесу</b>					
Увеличить продажи	✓			✓	
Продвигать более разнообразные айтемы		✓	✓	✓	
Улучшить пользовательский опыт	✓		✓	✓	✓
Добиться большей лояльности					✓
Лучше понимать пользователей					✓
<b>Пользователям</b>					
Найти лучший товар	✓			✓	✓
Найти <b>все</b> подходящие товары	✓	✓			✓
Найти последовательность или набор товаров			✓		✓
Залипнуть			✓	✓	✓
Найти рекомендер, которому можно доверять					✓
Помочь другим сделать выбор					✓

Оценка успешности идей  
оооооо

Оффлайн эксперимент  
оооо

Релевантность  
оооооооооооо

Покрытие  
ооо

Разнообразие  
оооо

Удачность  
оооооо

Бейзлайны  
●○

Итоги  
ооо

## Бейзлайны

## Простые бейзлайны

- позволяют определить нижнюю границу качества системы
- позволяют быстро стартануть

- Живительный рандом
- TopPopular
- Эвристики
- Редакторская подборка

Оценка успешности идей  
oooooooo

Оффлайн эксперимент  
oooo

Релевантность  
oooooooooooo

Покрытие  
ooo

Разнообразие  
oooo

Удачность  
oooooo

Бейзлайны  
oo

Итоги  
●oo

## Итоги

## Итоги

При выборе подхода к проверке гипотез, нужно иметь в виду компромисс надежности и скорости

Технические метрики отражают разные аспекты рекомендаций: релевантность, разнообразие, удачность

Don't be a hero: не связываемся со сложными алгоритмами, пока не заведем простые бейзлайны

## Литература I

-  Jaime G. Carbonell and Jade Goldstein, *The use of MMR, diversity-based reranking for reordering documents and producing summaries*, Research and Development in Information Retrieval, 1998, pp. 335–336.
-  Matevz Kunaver and Tomaz Pozrل, *Diversity in recommender systems - a survey*, Knowl. Based Syst. 123 (2017), 154–162.
-  Denis Kotkov, Shuaiqiang Wang, and Jari Veijalainen, *A survey of serendipity in recommender systems*, Knowledge-Based Systems 111 (2016).
-  Francesco Ricci, Lior Rokach, Bracha Shapira, and Paul B. Kantor, *Recommender systems handbook*, 1st ed., Springer-Verlag, Berlin, Heidelberg, 2010.
-  Moussa Taifi, *Mrr vs map vs ndcg: Rank-aware evaluation metrics and when to use them*, Nov 2019.